Ansätze und Überlegungen

Bjarne Jehn

2026

- Wir berechnen minimizer stats lediglich für das erste level. Kann davon ausgegangen werden, dass die Verteilung in den höheren ebenso ausfällt, da die Hashfunktion random ist?
  Oder ist es möglich, dass die Verteilung in höheren Leveln anders ausfällt, da die Abdeckung der Minimizer nicht 1:1 mit der Abdeckung der k-mere einhergeht? - überprüfen!

- greedy idee: für ein level lösen, dann für ein weiteres, dann für ein weiteres - wird nicht optimal werden aber eventuell besser als nur für ein level

- suchräume verkleinern: sind die parameter tatsächlich non-decreasing? Wenn ja, Begründen und eventuell ausnutzen

- lässt sich p_K eventuell anhand von m, t und der Textlänge T bestimmen, anstatt die Werte empirisch zu bestimmen? Dafür würde sprechen, dass die Hashfunktion zufällig ist. Dagegen könnte sprechen, dass repetitivität auf unbearbeiteten Genomen eine Rolle spielen könnte.
  Vermutlich ist das aber nicht der Fall und würde ansonsten den Sinn der Arbeit hinterfragen..
  Idee zur Untersuchung:

  - Aus verschiedenen Genomen jeweils die gleiche Menge an Abschnitten gleicher Länge samplen und für diese die Verteilung berechnen - sollten die Werte $p_K(m, t, T)$ vom Genom unabhängig sein und lediglich von m, t und T abhängen, dann müsste dies in ungefähr gleichen Verteilungen resultieren. Ist dies der Fall, müsste man überlegen, welchen Einfluss die jeweiligen parameter haben.
    Erste Annahme:
    $p_K(m, t, T)$ wird größer, je größer t, m sind und je kleiner T ist.